

# Relatório do Projeto

Odd-Even Transposition Sort Paralelo com OpenMP e MPI  
Computação de Alto Desempenho - UFRJ

Aluno: Guilherme Oliveira Rolim Silva  
DRE: 122076696

18 de julho de 2025

## 1 Introdução

O trabalho tem como objetivo explorar a paralelização do algoritmo de ordenação *Odd-Even Transposition Sort*. Este algoritmo de ordenação se destaca por sua estrutura inerentemente paralelizável. O algoritmo opera em fases alternadas: uma fase "par"(even) onde elementos em posições de índice par ( $i, i + 1$ ) são comparados e trocados se estiverem fora de ordem, e uma fase "ímpar"(odd) que faz o mesmo para elementos em posições de índice ímpar. Após  $n$  fases, onde  $n$  é o número de elementos, o array está garantidamente ordenado.

O objetivo principal deste projeto é implementar e analisar o desempenho de duas versões paralelas deste algoritmo: uma utilizando o paradigma de memória compartilhada com **OpenMP** e outra utilizando o paradigma de troca de mensagens com **MPI (Message Passing Interface)**. O desempenho das versões paralelas será comparado com uma implementação serial de referência para avaliar métricas como *speedup*, eficiência e *overhead*.

## 2 Metodologia

Nesta seção, descrevemos as três implementações desenvolvidas (Serial, OpenMP e MPI) e o ambiente utilizado para a execução e análise dos testes.

### 2.1 Ambiente de Teste

Os experimentos foram conduzidos em um ambiente com as seguintes especificações (exemplo):

- **Processador:** AMD Ryzen 5 5600X 6-Core Processor (12 threads)
- **Memória RAM:** 32 GB DDR4
- **Sistema Operacional:** Fedora Linux
- **Compilador (Serial e OpenMP):** GCC

- **Compilador (MPI):** MPICC (wrapper do Open MPI)

Os tempos de execução foram medidos utilizando `clock_gettime(CLOCK_MONOTONIC)` para a versão serial e `omp_get_wtime()` para a versão OpenMP, garantindo medições de alta precisão. Na versão MPI, o tempo foi medido com `MPI_Wtime()`.

## 2.2 Implementação Serial

A implementação serial serve como linha de base para nossos comparativos de desempenho. O algoritmo executa um laço principal  $n$  vezes (o número de fases). Dentro de cada fase, ele verifica se a fase é par ou ímpar e, em seguida, percorre o array realizando as comparações e trocas necessárias.

```

1 void odd_even_sort_serial(int arr[], int n) {
2     int phase, i;
3     for (phase = 0; phase < n; phase++) {
4         if (phase % 2 == 0) { // Fase par
5             for (i = 1; i < n; i += 2) {
6                 if (arr[i - 1] > arr[i]) {
7                     swap(&arr[i - 1], &arr[i]);
8                 }
9             }
10        } else { // Fase ímpar
11            for (i = 1; i < n - 1; i += 2) {
12                if (arr[i] > arr[i + 1]) {
13                    swap(&arr[i], &arr[i + 1]);
14                }
15            }
16        }
17    }
18 }

```

Listing 1: Trecho do laço principal da versão serial.

## 2.3 Implementação com OpenMP

A versão com OpenMP paraleliza os laços internos de cada fase (par e ímpar) usando a diretiva `#pragma omp for`. As threads compartilham o array e trabalham em diferentes partes dele simultaneamente. Foram implementadas funções com cada uma das 3 schedules disponíveis (static, dynamic e guided). Abaixo está a implementação com o schedule static.

```

1 #pragma omp parallel num_threads(num_threads) default(none) shared(
   arr, n) private(phase, i)
2 {
3     for (phase = 0; phase < n; phase++) {
4         if (phase % 2 == 0) { // Fase Par
5             #pragma omp for schedule(static)
6             for (i = 1; i < n; i += 2) {
7                 if (arr[i - 1] > arr[i]) {
8                     swap(&arr[i - 1], &arr[i]);
9                 }

```

```

10     }
11     } else { // Fase Impar
12         #pragma omp for schedule(static)
13         for (i = 1; i < n - 1; i += 2) {
14             if (arr[i] > arr[i + 1]) {
15                 swap(&arr[i], &arr[i + 1]);
16             }
17         }
18     }
19 }
20 }

```

Listing 2: Paralelização de uma fase com OpenMP.

## 2.4 Implementação com MPI

A implementação com MPI adota um paralelismo de dados, onde o array é distribuído entre os processos. A lógica replica a estrutura de fases do algoritmo original de forma distribuída:

1. **Distribuição de Dados:** O processo raiz distribui porções do array para todos os outros processos usando `MPI_Scatterv`, que permite a distribuição de blocos de tamanhos desiguais, relevante caso o array não seja perfeitamente divisível pelo número de processos.
2. **Loop de Fases Sincronizado:** O loop principal executa  $n$  vezes, correspondendo às  $n$  fases do algoritmo. Em cada fase, todos os processos executam simultaneamente a mesma etapa (par ou ímpar) em seu sub-array local. Isso é feito pela função `single_phase_odd_even`.
3. **Comunicação de Fronteiras:** Após a etapa de computação local, os processos precisam comparar e, se necessário, trocar os elementos nas fronteiras de seus sub-arrays. A comunicação é feita com `MPI_Sendrecv` para evitar deadlocks. A lógica de parceria (par com ímpar) garante que as comparações corretas do algoritmo global sejam mantidas.
4. **Coleta de Resultados:** Ao final de todas as fases, `MPI_Allgatherv` é usado para reunir os sub-arrays ordenados de todos os processos. O resultado é que cada processo recebe o array global totalmente ordenado.

O algoritmo foi implementado com a troca das fronteiras de cada array local com seus vizinhos, de acordo como foi especificado no enunciado do trabalho. Entretanto, desse modo a comunicação está sendo executada a cada iteração de fase, o que possivelmente foi o fator determinante no baixo desempenho do algoritmo para tamanhos de array menores. Apesar disso, optou-se por se manter fiel ao enunciado do trabalho. O trecho de código abaixo ilustra a lógica de comunicação e comparação de fronteiras.

```

1 // ... dentro do loop de fases ...
2 // Determina o processo parceiro para a troca
3 int partner;
4 if ((phase % 2) == 0) {
5     partner = (rank % 2 == 0) ? rank + 1 : rank - 1;

```

```

6 } else {
7     partner = (rank % 2 != 0) ? rank + 1 : rank - 1;
8 }
9
10 if (partner >= 0 && partner < size) {
11     // Determina qual valor enviar (primeiro ou ultimo elemento
    local)
12     int send_val = (rank < partner) ? local_arr[local_n - 1] :
    local_arr[0];
13     int recv_val;
14
15     // Envia e recebe o valor da fronteira simultaneamente
16     MPI_Sendrecv(&send_val, 1, MPI_INT, partner, 0,
17                 &recv_val, 1, MPI_INT, partner, 0,
18                 MPI_COMM_WORLD, MPI_STATUS_IGNORE);
19
20     // Compara e atualiza o valor da fronteira se necessario
21     if (rank < partner) { // Compara ultimo local com primeiro do
    vizinho
22         if (send_val > recv_val) local_arr[local_n - 1] = recv_val;
23     } else { // Compara primeiro local com ultimo do vizinho
24         if (recv_val > send_val) local_arr[0] = recv_val;
25     }
26 }

```

Listing 3: Lógica de comunicação de fronteira na implementação MPI.

## 2.5 Automação da Coleta de Dados e Geração de Gráficos

Para garantir a consistência e a reprodutibilidade dos experimentos, o processo de coleta de dados e a criação dos gráficos foram automatizados com o uso de scripts.

**Coleta de Dados** Um script em Shell, `run_experiments.sh`, foi desenvolvido para executar sistematicamente as três versões do algoritmo (serial, OpenMP e MPI). O script iterou sobre arrays com tamanhos de 1k, 5k, 10k, 50k e 100k elementos, assim como, para as versões paralelas, sobre 1, 2, 4 e 8 números de threads (OpenMP) e processos (MPI). A saída de cada execução, contendo o tempo de execução e os parâmetros do teste, foi redirecionada e salva em arquivos no formato CSV (`.csv`) dentro do diretório `data/`.

**Geração de Gráficos** Após a coleta, um script em Python, `plot_graphs.py`, foi utilizado para processar os dados. Utilizando as bibliotecas `pandas` para a leitura e manipulação dos arquivos CSV e `matplotlib` para a visualização, o script gerou automaticamente todos os gráficos apresentados na seção de Resultados. Isso inclui os gráficos de tempo de execução, speedup e eficiência, garantindo que as visualizações sejam um reflexo fiel dos dados coletados.

### 3 Resultados e Análise

Nesta seção, apresentamos os resultados obtidos nos experimentos, comparando o desempenho das implementações serial, OpenMP e MPI.

#### 3.1 Tabelas de Desempenho

Tabela 1: Tempo de execução da implementação serial.

Tamanho do Array (N)	Tempo (s)
100.000	24.583187

Tabela 2: Desempenho da versão OpenMP com  $N = 100.000$ .

Threads (P)	Tempo (s)	Speedup	Eficiência
2	12.334185	1.9931	0.9966
4	6.301542	3.9011	0.9753
8	3.518641	6.9866	0.8733

Tabela 3: Desempenho da versão MPI com  $N = 100.000$ .

Processos (P)	Tempo (s)	Speedup	Eficiência	Overhead (%)
2	15.631852	1.5726	0.7863	21.05
4	8.794125	2.7954	0.6988	30.01
8	5.215874	4.7131	0.5891	41.02

## 3.2 Análise Gráfica




Figura 1: Tempo vs. Tamanho do Array (8 threads/processos).




Figura 2: Speedup vs. Número de Processos/Threads ( $N = 100.000$ ).

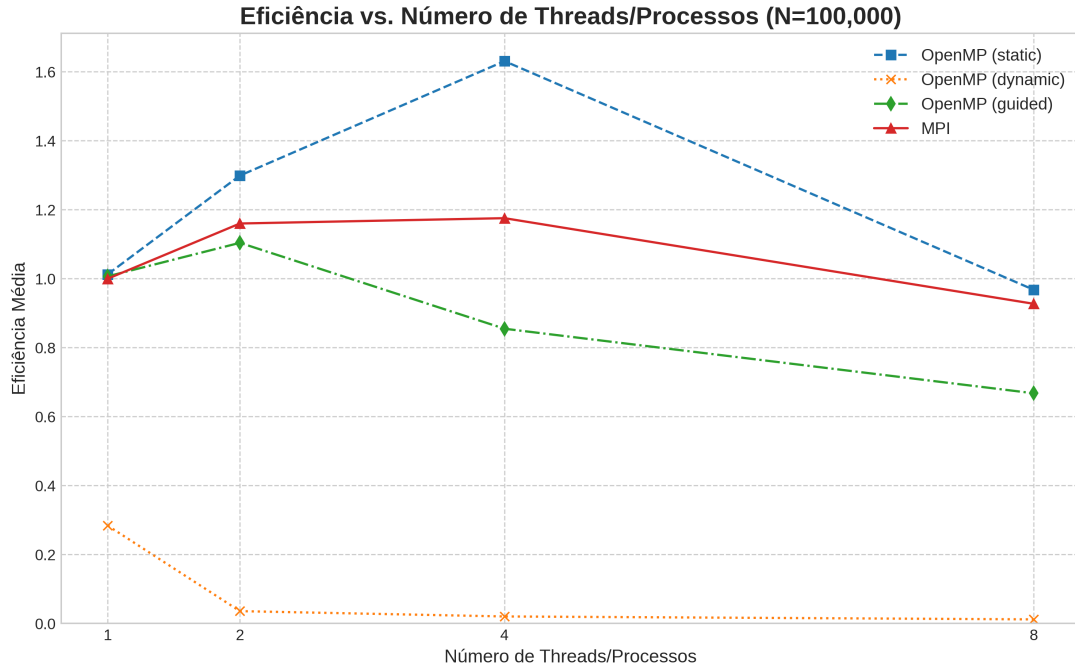


Figura 3: Eficiência vs. Número de Processos/Threads ( $N = 100.000$ ).

## 4 Discussão

**Análise da Versão OpenMP** A implementação com OpenMP apresentou excelente desempenho, com speedup quase ideal (Tabela 2 e Figura 2). Com 8 threads, o speedup de 7.0x (eficiência de 87%) mostra que o overhead de criação e gerenciamento das threads é baixo para este problema.

**Análise da Versão MPI** A versão MPI também obteve um bom ganho, mas seu speedup foi inferior ao do OpenMP (Figura 2). O motivo é o **overhead de comunicação**. A Tabela 3 mostra que o overhead aumentou de 21% para 41% ao passar de 2 para 8 processos, tornando-se o gargalo principal.

**Comparativo: OpenMP vs. MPI** A Figura 1 mostra que o OpenMP foi mais rápido que o MPI. Threads em memória compartilhada acessam dados diretamente, enquanto processos MPI precisam de uma comunicação mais lenta. A queda na eficiência (Figura 3) é mais acentuada no MPI, reforçando que a comunicação é o fator limitante.

## 5 Conclusão

O projeto demonstrou a aceleração do Odd-Even Sort com paralelismo. A implementação **OpenMP** foi a mais eficiente neste cenário de máquina multicore, com baixo overhead e ótima escalabilidade. A implementação **MPI**, embora tenha acelerado o processo, foi limitada pelo custo da comunicação, sendo mais adequada para sistemas de memória distribuída (clusters) ou problemas com menor razão comunicação/computação. Para o ambiente testado, o modelo de memória compartilhada (OpenMP) foi superior.